杨建国

求职意向：大模型应用开发 · Agent 开发

手机	136-0082-7058	邮箱	596629821@qq.com
GitHub	github.com/Ohh-Sillage	主页	yjgnet.cn
经验	5 年数据工程（ETL / 数仓 / 建模）+ 大模型应用落地		
学历	武汉科技大学 · 机械电子工程 · 本科（全日制）		

个人主页 · 在线可访问
yjgnet.cn
含在线 AI 助手 Demo，可直接体验

个人优势

- **端到端交付能力：** 5 年数据工程（ETL / 数仓 / 建模）打底，近 2 年聚焦大模型落地，能独立完成「数据 → 模型 → 服务 → 部署」全链路。
- **RAG 全链路工程化能力：** 独立完成上市公司年报 RAG 问答系统，覆盖解析 / 分块 / 混合检索 / 重排 / 生成 / 评估全链路，原生版（约 700 行）与 LangChain 版（约 200 行）双实现对照，配 20 题评测集与 RAGAS 四项指标量化效果。
- **技术选型判断力：** 在 CBLUE KUAKE-QIC（11 类医疗意图）上以同一数据、同一评估协议对比 BERT 微调与 LLM zero-shot / few-shot / LoRA SFT 四条路线，用实验结果而非经验确定「小数据 + 类别不平衡」场景的路线边界。
- **工程落地闭环：** 具备 FastAPI 服务化、Docker / Nginx 部署、SSE 流式与线上运维能力，个人主页 yjgnet.cn（含 AI 助手、日志与巡检告警）已稳定运行于自有服务器。

专业技能

编程语言	Python · SQL · Bash / Shell
AI / 机器学习	PyTorch · Transformers · LLM 微调（LoRA / SFT） · RAG · LangChain / LCEL · 向量数据库（FAISS） · BM25 / 混合检索 / RRF · Prompt 工程 · RAGAS 评测
工程与部署	FastAPI · Docker · Linux · Nginx · Git · CI/CD · SSE 流式 · WebSocket
数据与工具	Pandas / NumPy · MySQL · Oracle · Redis · Elasticsearch · ETL · 数据建模

工作经历

北京中普达科技股份有限公司 · 大数据工程师（医疗健康方向） 2022 — 2026

技术栈： Python · ETL · RAG · LLM · MySQL · Oracle

- 主导医疗健康领域多源异构数据 **ETL 全链路**建设：基于 Python 完成抽取、清洗、转换与分析处理，打通业务系统到分析层的规范化沉淀，为上层智能应用提供统一数据底座。
- 从 0 到 1 搭建 **LLM + RAG 智能检索问答系统**，将海量医疗数据的检索方式由关键词匹配升级为语义检索，实现精准查询与自然语言问答。
- 负责 Oracle / MySQL 侧的数据建模与查询优化，支撑生产运营分析与报表需求；并将沉淀后的结构化数据与大模型检索能力结合，形成业务可直接使用的查询入口。

宝钢德盛不锈钢有限公司 · 信息科 · 数据开发工程师 2020 — 2022

技术栈： Oracle · MySQL · SQL · 数据建模 · 数据采集

- 负责企业级数据库**架构设计与开发**，打通各业务系统的数据采集与入库链路，完成从数据源头到数据库的规范化沉淀。
- 设计并维护跨系统数据采集方案，解决多源数据口径不一致与入库延迟问题，为生产运营分析及智能化应用提供高质量数据底座。

项目经历

上市公司年报 RAG 问答系统 · 个人项目

技术栈： RAG · FAISS · BM25 / RRF · LangChain · CrossEncoder Rerank · FastAPI · RAGAS
github.com/Ohh-Sillage/Financial-Report-Rag

- **15 份真实年报 PDF（约 85 MB）**构建完整 RAG 流水线：数据取自巨潮资讯网 5 家公司 × 3 年，覆盖下载 → PDF 解析（含扫描件 OCR、嵌套表格转 Markdown）→ 分块 → 向量索引 → 混合检索 → 重排 → 生成 → 评估八个环节，数据噪声真实可复现。
- **原生版（约 700 行）与 LangChain LCEL 版（约 200 行）双实现对照**：原生版手动控制混合检索 + RRF 融合 + bge-reranker 精排，LangChain 版走框架封装，量化「可控性 vs 代码量」的框架选型取舍。
- 设计 **3 种分块策略（固定 / 语义 / 层级 Small-to-Big）× 3 种检索方式（向量 / BM25 / 混合）= 9 组消融实验**，以 Hit Rate@4 与 MRR 为指标完成策略选型，而非凭经验调参。
- 构建 **20 题五类评测集**（简单事实 / 精确数字 / 跨文档对比 / 跨年趋势 / 应拒绝回答）与 **RAGAS 四项指标**（Faithfulness、Answer Relevancy、Context Precision、Context Recall）评估体系，使效果可量化、可回归。
- 通过**相关性阈值拒答 + 逐条引用溯源**（定位到公司、章节与页码）抑制幻觉，回答可回溯至原文；并专门设置 3 道「应拒答题」验证拒答能力。
- 交付 CLI 交互 / 单次查询 / Python 模块 / FastAPI HTTP 服务 / 可视化页面五种使用方式；单次问答端到端 2–5 s，全量建索引成本约 0.35 元。

KUAKE-QIC 中文医疗意图分类：BERT 微调 vs LLM 三路对比 · 个人项目

技术栈： BERT · LoRA / SFT · PyTorch · Transformers · PEFT
github.com/Ohh-Sillage/kuaque-qic-bert-vs-llm

- **准确率 81.7%（BERT fine-tune，1,955 条全量验证集，macro-F1 77.7%）**：在同一数据集（CBLUE KUAKE-QIC，11 类医疗搜索意图）与同一评估协议下，对比判别式微调 / LLM zero-shot（29.0%）/ few-shot（25.5%）/ LoRA 指令微调（46.0%）四条路线，结论为判别式路线完胜生成式路线。
- 基于 bert-base-chinese **手写三种池化分类头并做消融**（cls 81.7% ≈ mean 80.9% > max 77.8%），用实验确定最优句向量提取方式。
- 针对 **24× 类别不均衡**引入加权 CrossEntropyLoss，配合分层学习率（BERT 层与分类头分离）与 Linear Warmup 稳定训练，并单独做加权 / 不加权的对照实验。
- 实现 **LoRA 参数高效微调（r=8）**：可训练参数 1.08M / 495M（仅 0.22%），含 chat 格式转换与 **loss masking**（仅对类别 token 计算损失），避免生成式训练的目标稀释。
- 完整记录负面结论并给出归因：few-shot 示例由 0 增至每类 3 条后准确率反而由 29.0% 降至 25.5%；zero-shot 存在 13% 输出无法解析——据此论证小数据场景下不应默认选择生成式路线。

个人主页 AI 助手（yjgnet.cn） · 个人项目 · 已上线

技术栈：FastAPI · SSE · Jinja2 · Nginx · systemd · LLM（OpenAI 兼容）
github.com/Ohh-Sillage/PersonalHomepage · 线上 yjgnet.cn

- 独立开发并上线个人主页：**FastAPI + Jinja2 服务端渲染 + 原生 CSS/JS，无前端构建链**，内容与代码分离（YAML 驱动），改文案无需重新构建。
- 实现 **SSE 流式 AI 助手**：基于个人知识库问答，未配置 Key 时走预设知识库、配置后自动切换 OpenAI 兼容真实模型（线上 DeepSeek），前端零改动。
- 设计**三层用量防护**：每 IP 每分钟限流、每 IP 每日限额、全站每日 token 预算，超限自动降级至预设知识库，防止 token 被恶意消耗。
- 构建访问日志与**安全事件归类**（扫描探测、4xx/5xx、限流拦截）中间件与真实 IP 解析，日志按天轮转自动保留 14 天。
- 实现服务器**每 5 分钟自动巡检**（服务 / 健康 / 磁盘 / 内存）与异常邮件告警（含恢复通知）、每周 7 天运行报告；部署于 Ubuntu + Nginx + systemd + Let's Encrypt，配套**一键分通道同步工具**。

在线视频实时字幕翻译（OnlineTranslation） · 个人项目

技术栈：faster-whisper · FastAPI · WebSocket · 浏览器扩展
github.com/Ohh-Sillage/OnlineTranslation

- 实现 Edge 浏览器在线视频的**实时字幕翻译**链路：捕获标签页音频 → 本地 faster-whisper 识别日 / 英语 → 译为中文 → 双语悬浮字幕呈现。
- 采用**本地推理 + WebSocket 实时推送**架构，音频全程不出本机，同时规避云端上传的隐私风险与网络往返延迟。
- 以**浏览器扩展**形态交付，无需改造视频源或安装本地客户端，即装即用。

技术写作 & 开源

技术写作 yjgnet.cn/blog（《RAG 知识库实践》《AI 工程化学习路线》）

开源　　4 个项目均含架构 / 使用 / 开发日志文档，可在线验证